

Se sube el dataset en Azure:

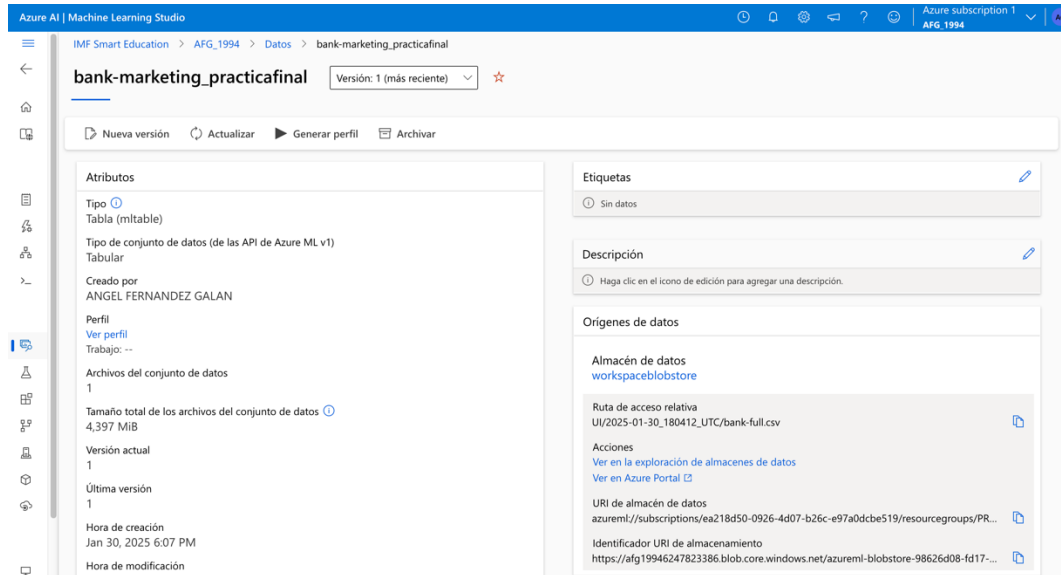


Figura 1. Carga del dataset bank-marketing

En un primer momento se crea un trabajo automatizado eligiendo la columna de destino (y) en el cluster de proceso, además de seleccionar un trabajo de clasificación. De esta forma se han obtenido la siguientes métricas:

Nombre del algoritmo	Explicado	IA responsable	Valor pondera...	Muestreo	Fecha de creación	Duración
VotingEnsemble	Ver explicación		0.93249	100.00 %	Feb 5, 2025 1:32 AM	1 m 44 s
MaxAbsScaler, LightGBM			0.93114	100.00 %	Feb 4, 2025 7:31 PM	25 s
StandardScalerWrapper, XGBoostClassifier			0.92813	100.00 %	Feb 4, 2025 7:47 PM	59 s
StandardScalerWrapper, XGBoostClassifier			0.92761	100.00 %	Feb 4, 2025 8:34 PM	58 s
StandardScalerWrapper, XGBoostClassifier			0.92721	100.00 %	Feb 5, 2025 1:26 AM	56 s
StandardScalerWrapper, XGBoostClassifier			0.92715	100.00 %	Feb 5, 2025 1:29 AM	50 s
StandardScalerWrapper, XGBoostClassifier			0.92713	100.00 %	Feb 5, 2025 1:10 AM	1 m 35 s
StandardScalerWrapper, XGBoostClassifier			0.92704	100.00 %	Feb 4, 2025 8:47 PM	56 s

Figura 2. Algoritmos ordenados de mayor a menor por la métrica indicada

Como información general dentro del modelo se ha seleccionado de entre todos las pruebas el algoritmo de “VotingEnsemble” como el que mejor valor UAC tiene con respecto al resto mostrando en la anterior imagen.

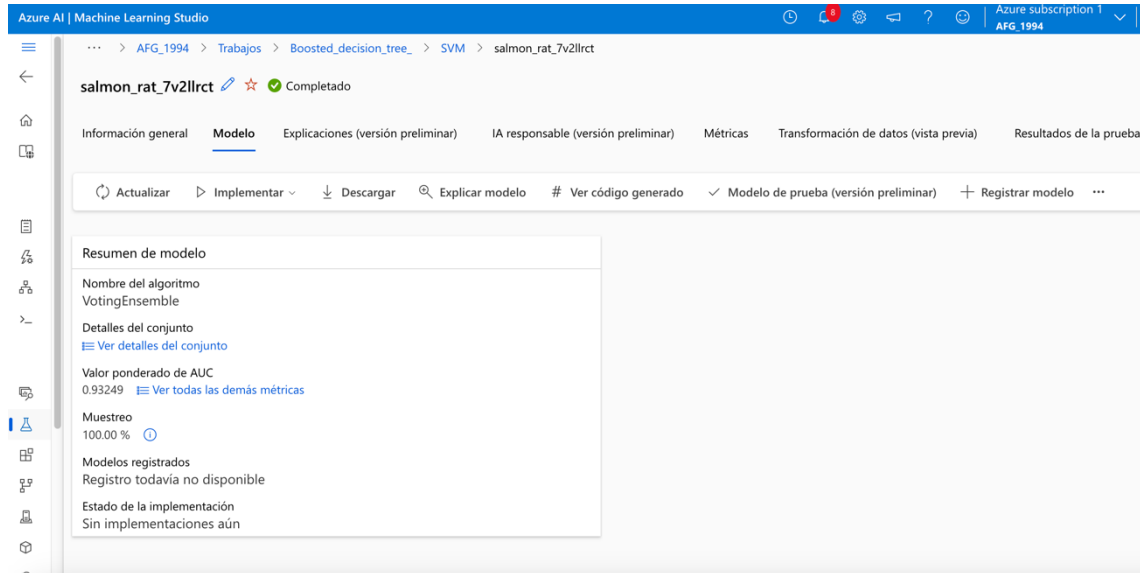


Figura 3. Información general del modelo

En la siguiente imagen se puede apreciar las diferentes métricas obtenidas con respecto a los datos estadísticos tras el entrenamiento del algoritmo:

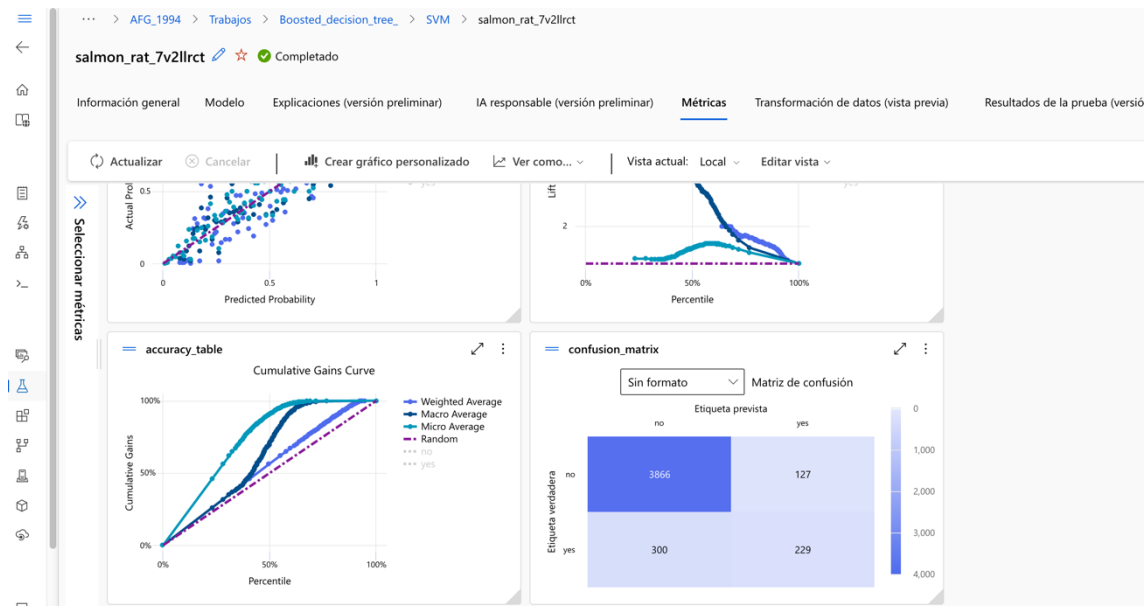


Figura 4. Métricas del modelo

Siendo la ingeniería de características del modelo la siguiente:

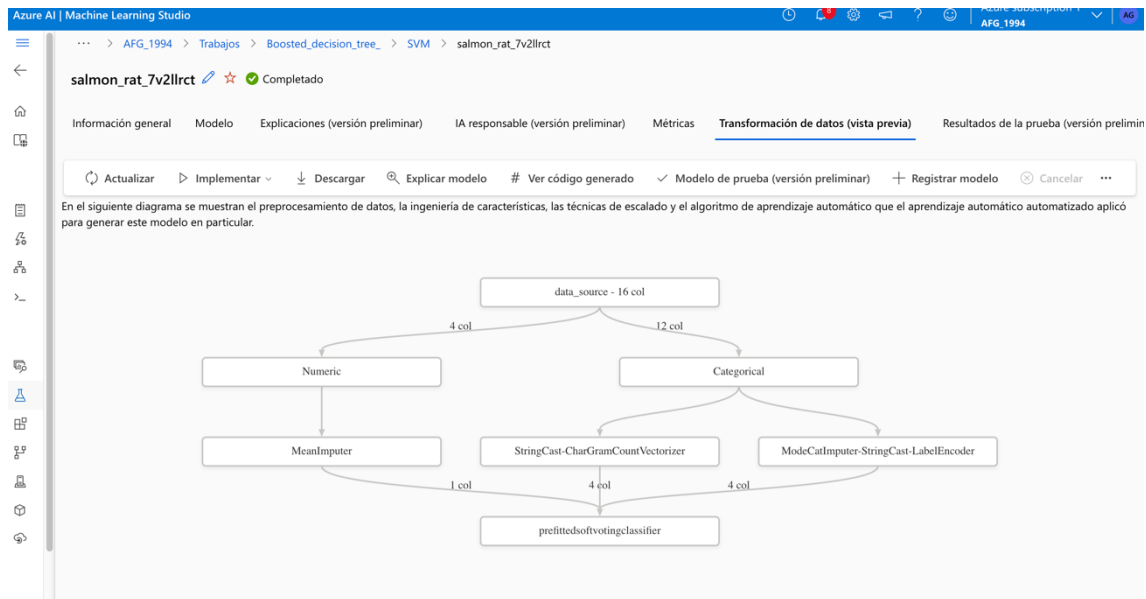


Figura 5. Ingeniería de características del proceso

En paralelo se ha ido probando con diferentes tipos de modelos como son *Decision tree*, *perceptron promedio*, *SVM* y *two class decisión forest*, obteniendo los siguientes resultados:

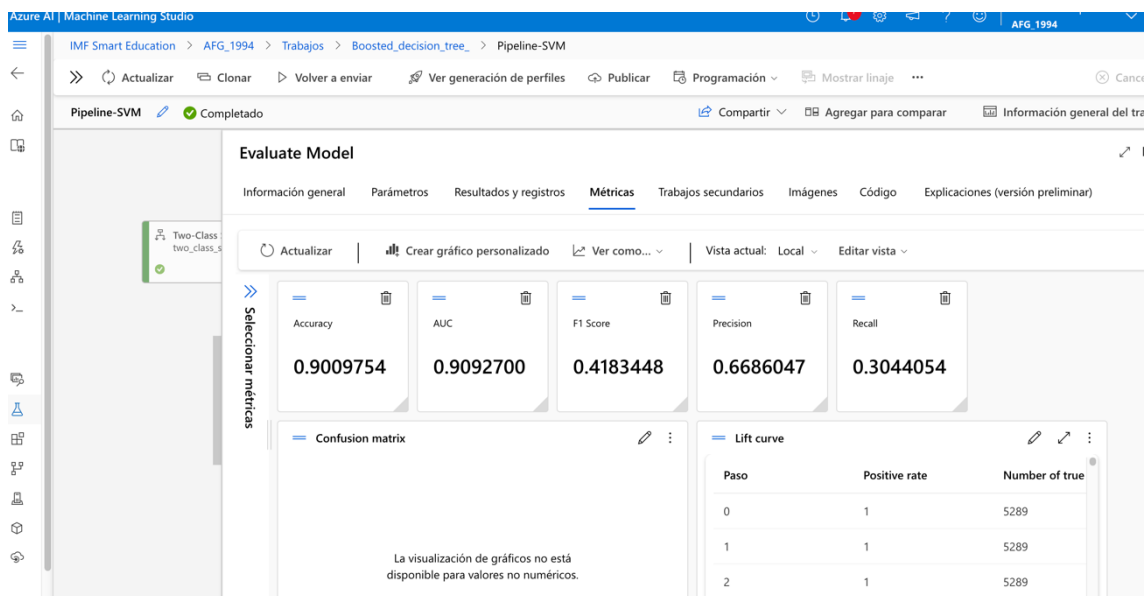


Figura 6. Métricas obtenidas a través del pipeline SVM

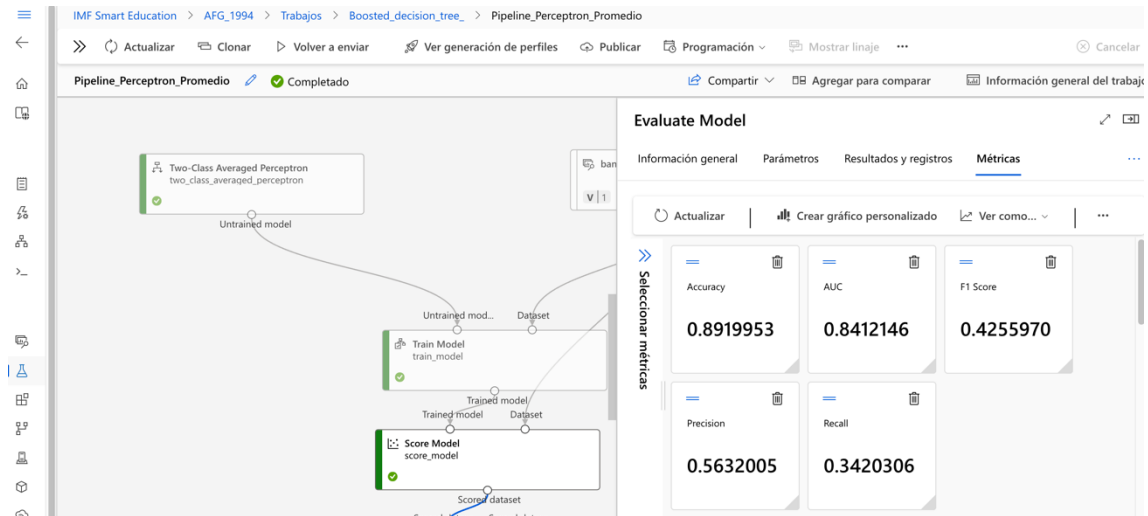


Figura 7. Métricas obtenidas a través del pipeline Perceptron Promedio

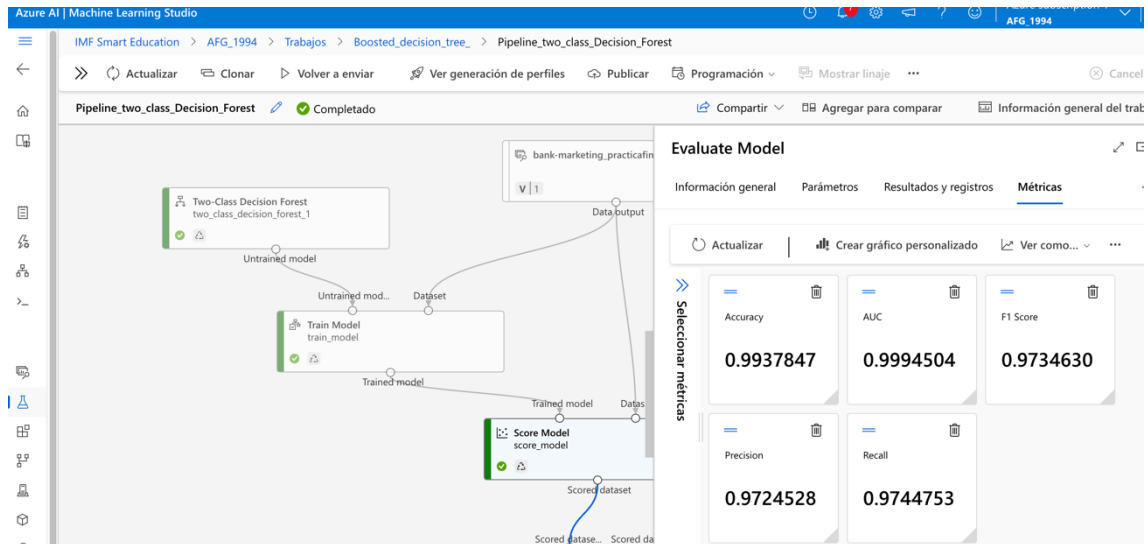


Figura 8. Métricas obtenidas a través del pipeline two class decision forest

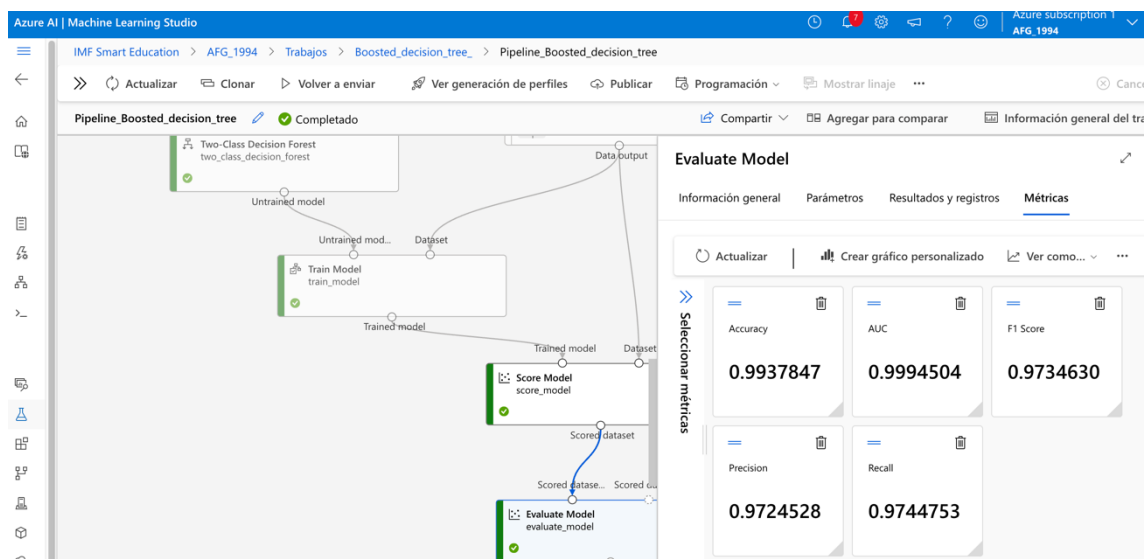


Figura 9. Métricas obtenidas a través del pipeline boosted decision tree

A continuación se detalla la justificación y el razonamiento que nos ha llevado a elegir el modelo con mejores métricas para su puesta en producción:

1. Pipeline: Boosted Decision Tree

- Accuracy: 0.9938
- AUC: 0.9995
- F1 Score: 0.9735
- Precision: 0.9725
- Recall: 0.9745
-

Este modelo tiene métricas altas, con una AUC cercana a 1, lo que indica una buena capacidad para distinguir entre clases. Además, su F1 Score (0.9735) refleja un buen equilibrio entre precisión y recall. Este modelo parece ser el más robusto y adecuado para desplegar en producción.

2. Pipeline: Two-Class Averaged Perceptron

- Accuracy: 0.8920
- AUC: 0.8412
- F1 Score: 0.4256
- Precision: 0.5632
- Recall: 0.3420

El modelo de Perceptrón Promedio tiene un desempeño significativamente inferior en comparación con otros modelos. Su AUC (0.8412) es moderada, pero el F1 Score (0.4256) indica un desequilibrio entre precisión y recall, con un recall especialmente bajo. Este modelo no sería ideal para un caso de producción.

3. Pipeline: Support Vector Machine (SVM)

- Accuracy: 0.9010
- AUC: 0.9093
- F1 Score: 0.4183
- Precision: 0.6686
- Recall: 0.3044

Aunque este modelo tiene un AUC relativamente alto (0.9093), el F1 Score es bajo (0.4183), y el recall (0.3044) indica que el modelo no está capturando adecuadamente los positivos reales. Esto lo hace menos confiable para un despliegue en producción.

4. Pipeline: Two-Class Decision Forest

- Accuracy: 0.9938
- AUC: 0.9995
- F1 Score: 0.9735
- Precision: 0.9725
- Recall: 0.9745

Las métricas de este modelo son idénticas a las del Boosted Decision Tree, mostrando un excelente rendimiento en todas las métricas clave. Este modelo también es una excelente opción para desplegar en producción.

Hay que tener en cuenta que Aunque el modelo Voting Ensemble es robusto y tiene un buen rendimiento, no supera a los mejores pipelines evaluados anteriormente. Tanto el Boosted Decision Tree como el Two-Class Decision Forest son opciones más sólidas debido a un valor de AUC de (0.9995) y su equilibrio entre precisión y recall (F1 Score = 0.9735).

Con respecto a los resultados obtenidos cabe destacar que tanto los modelos de boosted decision tree y two-class decision forest, tiene métricas muy similares y son ideales con respecto al resto para su despliegue en producción, siendo la diferencia de ambos las siguientes:

- **Boosted Decision Tree:** Puede ser más eficiente para manejar datos desbalanceados gracias a su enfoque en errores acumulativos.
- **Decision Forest:** Es más robusto y rápido en escenarios con gran volumen de datos debido a su diseño paralelo.

Por lo tanto, dado el contexto de la empresa, con una infraestructura en la nube basada en sistemas serverless y una escala pequeña (15 empleados), el modelo Two-Class Decision Forest es la mejor opción para el despliegue en producción. Este modelo destaca por su velocidad de entrenamiento e inferencia, su bajo consumo de recursos y su robustez frente a datos ruidosos.

Finalmente el endpoint de la canalización **Pipeline_two_class_Decision_** ha sido configurado para ejecutar tareas por lotes en Azure Machine Learning, utilizando el modelo seleccionado. Este endpoint está en estado **activo**, lo que garantiza su disponibilidad para integrarse en flujos de trabajo externos mediante la **URL REST** proporcionada, permitiendo enviar solicitudes de ejecución con datos específicos. Esta configuración es ideal para el escenario planteado, donde los datos se procesan periódicamente en la nube y se integran con herramientas como Power BI para análisis en tiempo real, asegurando eficiencia, automatización y escalabilidad en la estrategia de analítica de la empresa.

Canalizaciones

Trabajos de canalización | **Puntos de conexión de canalización** | Borradores de canalización

Actualizar | Deshabilitar | Habilitar | Restablecer vista | Incluir deshabilitados

Buscar | Filtrar | Estado: Activo | Columnas

Nombre	Descripción	Fecha de actualización	Actualizado por	Hora de envío del último...	Estado del último...	Estado
Pipeline_two_class_Decision_	--	Feb 6, 2025 8:33 PM	ANGEL FERNANDEZ GALAN	--	Sin iniciar	Activo

Página 1 de 1 | 25/Página

Figura 10. Puntos de conexión de canalización

Pipeline_two_class_Decision_

Detalles | Canalizaciones publicadas

Actualizar | Enviar | Clonar | Mostrar linaje

Búsqueda en el lienzo | Ocultar información general

Información general sobre los puntos de conexión de las canalizaciones

Información general | Configuración

Propiedades

- Estado: Active
- Punto de conexión REST: https://northeurope.api.azureml.ms/pipelines/v1.0/subscriptions/ea218d50-0926-4d07-b26c-e97a0dcbe519/resourceGroups/PRUEBAFINAL-IMF/providers/Microsoft.MachineLearningServices/workspaces/AFG_1994/PipelineRuns/PipelineEndpointSubmit/Id/7b2a9723-8ee5-4e13-815b-b60e53b0834c
- Documentación sobre puntos de conexión REST: <https://northeurope.api.azureml.ms/pipelines/swagger/pipelineendpointsubmit/swagger.json>

Etiquetas

- azureml.Designer: true

Descripción

--

Figura 11. URL para consumir el endpoint